

Verificación de supuestos del modelo ARIMA

```
c:\Users\narro\miniconda3\Lib\site-packages\statsmodels\base\model.py:607: ConvergenceWarning:
```

```
Maximum Likelihood optimization failed to converge. Check mle_retvals
```

1. Modelo ARMA(0,2,1)

$$\nabla^2 T(\text{IPC}_t) = (1 - 0.6817B)\tilde{Z}_t$$

Es decir:

$$= \tilde{Z}_t - 0.6817\tilde{Z}_{t-1}$$

Análisis de residuos

Supuesto 1: Errores con media cero

- Hipótesis nula:
 $H_0 : \mu_\varepsilon = 0$
- Hipótesis alternativa:
 $H_1 : \mu_\varepsilon \neq 0$

Estadístico de prueba:

$$t_0 = \frac{\bar{X}_\varepsilon}{S_\varepsilon/\sqrt{n}} \sim t(n-1)$$

Resultado del test t (R output):

One Sample t-test

```
data: resint_ARIMA021
t = -0.022657, df = 89, p-value = 0.982
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 -9.79742e-05  9.73261e-05
sample estimates:
mean of x
-3.20478e-07
```

Interpretación

Como:

$$p\text{-valor} = 0.982 > \alpha = 0.01$$

No tenemos suficiente evidencia estadística para rechazar que $\mu_\varepsilon = 0$

Por lo tanto, **se verifica el supuesto de media cero** en los residuos.

Supuesto 2: La varianza de los errores es constante

i) Prueba de Breusch–Pagan

- H_0 : Homocedasticidad (varianza constante)
- H_1 : Heterocedasticidad (varianza no constante)

ii) Gráfico de residuos contra tiempo

Este gráfico ayuda a detectar visualmente si la dispersión de los residuos varía a lo largo del tiempo. Si la nube de puntos se ensancha o estrecha sistemáticamente, puede haber heterocedasticidad.

Prueba de Breusch–Pagan

Se utiliza esta prueba para detectar si la varianza de los errores es constante (homocedasticidad) o cambia a lo largo del tiempo (heterocedasticidad).


Resultado del test (Breusch–Pagan studentizado)

studentized Breusch-Pagan test

data: modelo

BP = 1.1253, df = 1, p-value = 0.2888

resIPC_ARIMA021



Supuesto 3: Los errores tienen distribución normal

- i) Pruebas de normalidad
- ii) Histograma y gráfico Q-Q
- iii) Regla empírica (68-95-99.7%)
- iiii) Prueba de normalidad formal (Anderson–Darling)

Test de Anderson–Darling


- **Hipótesis nula:** H_0 = Normalidad
- **Hipótesis alternativa:** H_1 = No normalidad

Anderson-Darling normality test


data: resIPC_ARIMA021

A = 1.235, p-value = 0.003061


Histograma de los errores



QQ-plot de los errores



resIPC_ARIMA021 con Bandas $\pm 2\sigma$



- **Hipótesis nula:** H_0 = normalidad
- **Hipótesis alternativa:** H_1 = no normalidad

Resultado del test de normalidad

- Se utilizó el test de **Anderson–Darling**
- Se obtuvo un **p-valor = 0.003**
- Nivel de significancia $\alpha = 0.01$

Interpretación

Como:

$$p\text{-valor} = 0.003 < \alpha = 0.01$$

Rechazamos H_0 y aceptamos H_1 con un 99% de confianza.


Por lo tanto, no se verifica el supuesto de normalidad.

Supuesto 4: Errores independientes

- i) Prueba de Box–Pierce / Ljung–Box
- ii) Autocorrelaciones de los residuos

```
c:\Users\narro\miniconda3\Lib\site-packages\statsmodels\base\model.py:607: ConvergenceWarning:
```

```
Maximum Likelihood optimization failed to converge. Check mle_retvals
```



Box--Pierce test: $X^2 = 1.2101$, $df = 1$, $p\text{-value} = 0.2713$

Hipótesis

- H_0 : independencia
- H_1 : no independencia

Resultados

Se aplicó la prueba de **Box–Pierce / Ljung–Box** sobre los residuos.

- Se obtuvo un **p-valor** $> \alpha$
- Nivel de significancia: α

Conclusión

Como:

$$p\text{-valor} > \alpha$$

No tenemos suficiente evidencia estadística para rechazar H_0 Por lo tanto, se **verifica el supuesto de independencia**.

Además, el **gráfico de las autocorrelaciones muestrales de los residuos** confirma visualmente la verificación de este supuesto, ya que **todas las barras se encuentran dentro del intervalo de confianza**.

Supuesto 5: Parsimonia e inferencia sobre los parámetros

Principio de parsimonia

El **principio de parsimonia** indica que **el mejor modelo** es aquel que **utiliza la menor cantidad posible de parámetros** para explicar adecuadamente el fenómeno en estudio.

En otras palabras, **menos es más**:

Debe preferirse un modelo más simple si explica los datos casi igual de bien que uno más complejo.

Inferencia sobre los parámetros

Una forma de verificar la **significancia de los parámetros estimados** es analizando sus **intervalos de confianza al 95%**.

Ejemplo:

	2.5 %	97.5 %
ma1	-0.8633673442	-0.5001092211
intercept	0.0002062849	0.0002073526